

Procédure formalisée de bonnes pratiques sur la collecte, l'exploration et le nettoyage des données

Sommaire :

- 1) Le processus de collecte de données
 - a. RGPD
 - b. Les objectifs
 - c. La préparation
 - d. La méthode de collecte
 - e. Documentation
- 2) L'exploration des données
 - a. Préparation à l'exploration
 - b. Outils d'analyse
- 3) Le nettoyage des données
 - a. Identification des anomalies
 - b. Corriger les anomalies
 - c. Standardiser le processus de nettoyage
 - d. Validation des données
 - e. Documentation

1) Le processus de collecte des données

La collecte de données consiste à analyser et identifier les données pertinentes. Le processus de collecte de données est très important. Une bonne collecte permettra des analyses et des décisions adaptées aux études et/ou interrogations. Il est important de garder à l'esprit que les données doivent être :

- De qualité
- Fraîche
- Sécurisée
- Conforme
- Intègre
- Disponible
- Cohérente
- Tracée
- Complète et précise

A) RGPD

Le règlement général sur la protection des données a été mis en place pour formaliser les informations que les entreprises traitent et gèrent. Il a également été mis en place pour éviter un traitement abusif des données étant donné leurs caractères sensibles. Il apporte donc un cadre légal aux entreprises mais également aux consommateurs car cela leur permet de savoir comment leurs données sont collectées, traitées, archivées et supprimées. Il est donc essentiel de prendre en compte le RGPD lors de la collecte des données pour que celle-ci soit conforme.

B) Les objectifs

Définir les objectifs et les besoins de la collecte des données. Ces objectifs permettront de déterminer les questions auxquelles les données doivent répondre

C) La préparation

Il est important de définir les sources de données (interne ou externes) qui seront utilisées (base de données, rapports internes, enquêtes, données publiques etc)

D) La méthode de collecte

Il faut automatiser la collecte des données pour optimiser le temps et être en capacité d'assurer la bonne collecte des données

E) Documentation

Il faut mettre en place une documentation qui indiquera les outils utilisés pour la collecte des données et pour mesurer la fiabilité des données collectées.

2) L'exploration des données

A) Préparation à l'exploration

Vérification du format des fichiers collectés.

B) Outils d'analyse

Définir les outils qui permettront d'analyser les données collectées et qui permettront l'analyse des données et sa visualisation.

3) Le nettoyage des données

A) Identification des anomalies

Identifications des doublons, des valeurs manquantes et incohérentes.

B) Corriger les anomalies

Élimination des doublons

Corriger les incohérences

Remplacer et/ou remplir les valeurs manquantes

Suppression des anomalies inexploitable

C) Standardiser le processus de nettoyage

Détecter les anomalies automatiquement afin d'optimiser le temps et de reproduire facilement le processus.

Définir la fréquence de nettoyage des données.

D) Validation des données

Contrôle des données après nettoyage (vérification qu'il n'y ait plus d'anomalie)

Contrôle de la qualité des données (cf 1_Le processus de collecte de données)

Validation des données pour analyse

E) Documentation

Noter les modifications des données à chaque étape de traitement

Notifier les différentes personnes ayant accès ou travaillant sur la collecte de données des modifications

F) Archivage des données

Définir un délai d'archivage pour les données.

Lister et documenter les données archivés suite au nettoyage

G) Suppression des données

Définir un délai pour les suppressions des données

Lister et documents toutes les suppressions des données